

Extraction des structures de composés polyazotés

depuis la bibliographie et génération de fichiers .xyz

Gilles Frapper
Professeur des Universités en Chimie Théorique
IC2MP UMR 7285 CNRS, Université de Poitiers
gilles.frapper@univ-poitiers.fr

September 5, 2026

Abstract

Ce rapport documente l'extraction systématique des géométries moléculaires de composés N_n ($n = 2$ à 20, neutres, cations et anions) rapportées dans deux articles de référence du dossier `biblio_polyN/`, et leur conversion en fichiers de coordonnées cartésiennes au format `.xyz`, directement lisibles par le logiciel de visualisation cristallographique **VESTA**. Soixante-dix structures distinctes ont été produites. Pour chacune, la méthode de reconstruction (exacte à partir des paramètres publiés, ou topologie publiée relaxée par optimisation GFN2-xTB) est tracée et reportée.

1. Sources bibliographiques

Deux documents du dossier `biblio_polyN/` ont été dépouillés intégralement (texte et figures) :

- **[GS]** M. N. Glukhovtsev, H. Jiao, P. v. R. Schleyer, “*Besides N_2 , What Is the Most Stable Molecule Composed Only of Nitrogen Atoms?*”, *Inorg. Chem.* **1996**, *35*, 7124–7133 (fichier `poly-N.pdf`, 10 pages). Cet article (ab initio / DFT, HF, MP2, B3LYP) couvre les isomères de N_4 , N_6 , N_8 (dont l’azidopentazole et l’octaazapentalene, aromatiques), N_{10} (bispentazole), N_{12} et le dodécaèdre N_{20} .
- **[B]** S. Fau, M. Tobita, K. Wilson, A. Perera, R. J. Bartlett, “*Structure and Stability of Polynitrogen Molecules and Their Spectroscopic Characteristics*”, Quantum Theory Project, University of Florida (fichier `polynitrogen1.pdf`, 80 pages). Ce rapport (B3LYP/aug-cc-pVDZ, avec vérifications CCSD(T) pour les espèces les plus significatives) recense systématiquement tous les isomères $N_n^{0/\pm}$ trouvés liés entre $n = 2$ et $n = 10$, avec structures, fréquences de vibration, énergies relatives et enthalpies de formation.

Pour chaque molécule, les longueurs de liaison et angles de valence annotés sur les figures de structure ont été relevés, ainsi que le groupe ponctuel de symétrie, la multiplicité de spin, la charge et le niveau de théorie. Lorsque plusieurs niveaux de calcul étaient disponibles pour une même espèce, la géométrie CCSD(T) (la plus fiable) a été préférée à B3LYP.

2. Méthodologie de reconstruction 3D

Les figures des deux articles ne donnent, dans l’immense majorité des cas, que des longueurs de liaison et des angles de valence – jamais les angles dièdres complets (le rapport [B] le précise explicitement : “*To avoid overloading each picture, we have not included the dihedral angles, which are necessary to completely specify non-planar structures*”). Une recon-

struction rigoureuse des coordonnées cartésiennes exige donc une analyse au cas par cas de la symétrie moléculaire pour déterminer si ces paramètres suffisent à fixer entièrement la géométrie.

2.1 Niveau 1 — reconstruction géométrique exacte

Pour une majorité de structures, le groupe ponctuel annoncé implique que la molécule est **plane** (chaines en zigzag $C_s/C_2/C_{2v}/C_{2h}$ dont le mode de vibration “out-of-plane bend” confirme la planéité à l’équilibre, cycles D_{nh} réguliers ou irréguliers) ou bien possède une symétrie assez élevée (T_d , O_h , D_{3h} , D_{2d} , I_h , D_{nh} pour les prismes) pour que les longueurs de liaison et angles publiés déterminent entièrement la structure 3D, sans ambiguïté diédrale. Dans ces cas (45 structures sur 70), les coordonnées ont été calculées **analytiquement** : propagation d’une chaîne plane (zigzag), fermeture de cycle, ou constructions de symétrie fermées (tétraèdre, cube, prisme droit éclipsé, bipyramide trigonale sans atome central, cycle à 4 plisse D_{2d} , paire de cycles reliés perpendiculairement). Un script Python (`build/geom.py`, `build/molecules.py`) implémente ces constructions et vérifie, pour chaque liaison publiée, que la distance interatomique reconstruite correspond à la valeur annoncée (écart maximal reporté dans `build/manifest.json`; écarts observés $\leq 0,15$ Å, attribuables aux arrondis des valeurs publiées).

2.2 Niveau 2 — topologie publiée, géométrie relaxée par GFN2-xTB

Pour les 25 structures restantes – cages non planes (“log carrier”, “book”, “cap”, “ladder”, papillon N_4 , cycles fusionnés de type pentalène ou azulene, cycles à 8 non plans de type cyclooctatétrène...) – les angles dièdres nécessaires ne sont pas publiés et ne peuvent être déduits de la seule symétrie. La **connectivité** (topologie) décrite dans la référence a néanmoins été conservée : une géométrie 3D de départ raisonnable (cycle(s), chaîne ou agrégat compact, selon la description textuelle de la référence – voir la colonne “description” du tableau des enthalpies de formation de [B]) est construite, puis relaxée par **optimisation de géométrie GFN2-xTB** (xtb 6.6.1, méthode tight-binding semi-empirique déjà utilisée par le pipeline principal de ce dépôt, `polyN_pipeline.py`), à charge et multiplicité de spin fixées d’après la référence. Un pré-passage GFN-FF (champ de force) est utilisé en secours lorsque l’auto-cohérence GFN2 ne converge pas directement depuis le départ générique.

Ces 25 structures sont donc illustratives et topologiquement fidèles, mais leurs longueurs de liaison exactes peuvent différer légèrement des valeurs DFT/CCSD(T) publiées. Elles sont clairement identifiées dans le tableau 3 (colonne “Statut”) et dans le commentaire (2^e ligne) de chaque fichier `.xyz`.

2.3 Validation

Chaque structure produite a été contrôlée automatiquement :

- absence de valeurs non-numériques (NaN) ;
- distance interatomique minimale $> 0,6$ Å (pas de recouvrement d’atomes) ;
- distance au plus proche voisin $< 2,2$ Å pour chaque atome (pas de fragment dissocié / atome isolé).

Les 70 fichiers produits passent ces trois contrôles.

3. Format des fichiers produits

Chaque fichier `xyz/<id>.xyz` suit le format standard :

```
<nombre d'atomes>
<formule> charge=<q> mult=<2S+1> PG=<groupe ponctuel> | <methode> | src: <reference>
N   x1  y1  z1
N   x2  y2  z2
...
```


Ce format est importé directement par VESTA (*File > Open*, puis choisir “.xyz” comme type de fichier), qui reconnaît automatiquement l'espèce atomique (N, et H pour le pentazole neutre) et propose la représentation en boules-bâtons.

4. Résultats


4.1 Aperçu visuel

La figure 1 montre dix structures représentatives, de l'azote moléculaire aux cages les plus complexes.


N4 (Td)




N4 (C2v, 'papillon')




N5H (pentazole)




N5- (D5h, pentazolate)




N6 (D3h, prisme)




N8 (Oh, cubane)



N8 (D2h, octaazapentalene)



N10 (D5h, prisme pentagonal)



N10 (D2d, bispentazole)

N20 (Ih, dodecaedrane)

4.2 Bilan quantitatif

Structures reconstruites (total)	70
dont géométrie exacte (Niveau 1)	45
dont topologie + relaxation GFN2-xTB (Niveau 2)	25
Espèces couvertes	N ₂ à N ₂₀
États de charge	neutre, cation (+1), anion (−1)

Table 1: Bilan quantitatif de l'extraction bibliographique.

4.3 Répartition par formule et état de charge

Le tableau ci-dessous détaille, pour chaque composition N_n, le nombre de structures neutres, anioniques et cationiques extraites – N_n[−] étant compté séparément de N_n⁺, les deux espèces différant souvent fortement de géométrie et de symétrie.

Formule	Neutre	Anion (N [−])	Cation (N ⁺)	Total
N ₂	1	—	1	2
N ₃	1	3	2	6
N ₄	5	2	1	8
N ₅	1	2	1	4
N ₆	4	2	3	9
N ₇	3	1	1	5
N ₈	15	2	—	17
N ₉	2	3	2	7
N ₁₀	7	1	2	10
N ₁₂	1	—	—	1
N ₂₀	1	—	—	1
Total	41	16	13	70

Table 2: Répartition des 70 structures extraites par formule N_n et état de charge.

Détail des isomères retenus pour chaque couple (formule, charge) :

N₂	Neutre : N2. — Cation : N2+.
N₃	Neutre (radicalaire) : N3_radical. — Anion (3) : N3-_bent, N3-_linear, N3-_triangle. — Cation (2) : N3+_linear, N3+_triangle.
N₄	Neutre (5) : N4_C2h_chain, N4_C2v_butterfly, N4_D2d_puckered, N4_D2h_rectangle_planar, N4_Td. — Anion (2) : N4-_chain_planar, N4-_rectangle. — Cation : N4+_rectangle.
N₅	Neutre (protoné, pentazole) : N5H_pentazole. — Anion (2) : N5-_bipyramid, N5-_pentagon. — Cation : N5+_Vchain.
N₆	Neutre (4) : N6_C2_book, N6_C2h_chain, N6_D2_twisted, N6_D3h_prism. — Anion (2) : N6-_C2_linked_triangles, N6-_Cs_chain. — Cation (3) : N6+_C2h_nonplanar, N6+_C2h_planar, N6+_C2v.
N₇	Neutre (3) : N7_C2_linearZZ, N7_C2v_logcarrier, N7-Cs_ring_chain. — Anion : N7-_chain. — Cation : N7+_chain.

- N₈** Neutre (15) : N8_C1_ZZE, N8_C2h_EEE, N8_C2h_ladder, N8_C2h_ZEZ, N8_C2v_branched, N8_C2v_EZE, N8_C2v_ring, N8-Cs_azidopentazole, N8-Cs_pentagonal, N8-Cs_ZEE, N8_D2d_octaazacyclopentadiene, N8_D2h_pentalene, N8_D2h_ring_pendant, N8_0h_cubane_GS, N8_0h_cube. — Anion (2) : N8-_C2h_chain, N8-_C2h_ZEZ. — Cation : aucun.
- N₉** Neutre (2) : N9_chain, N9_fused_rings. — Anion (3) : N9-_chain, N9-_chain_twistedW, N9-_ring_chain. — Cation (2) : N9+_chain, N9+_fused_rings.
- N₁₀** Neutre (7) : N10_C3_cap, N10_cage_C2v, N10-Cs_ring_chain, N10_D10h_ring, N10_D2d_bispentazole, N10_D2d_linked5rings, N10_D5h_prism. — Anion : N10-_D2h_perp_rings. — Cation (2) : N10+_chain, N10+_rings.
- N₁₂** Neutre : N12_C2h_dipentazolyldiazene. — Ni anion ni cation dans le jeu extrait.
- N₂₀** Neutre : N20_Ih_dodecahedrane. — Ni anion ni cation dans le jeu extrait.

On note que N₈ concentre à lui seul 17 des 70 structures (tous les isomères de conformation E/Z de la chaîne octaazotée de [B]), sans cation recensé pour cette formule, tandis que N₁₂ et N₂₀ n'apparaissent qu'au travers d'une unique espèce neutre emblématique (le dipentazolyldiazène et le dodécaèdre, respectivement).

4.4 Table complète des structures

Le tableau 3 liste l'ensemble des 70 fichiers .xyz produits dans `biblio_polyN/xyz/`, avec la formule, le groupe ponctuel, le niveau de théorie de la géométrie de référence et le statut de reconstruction.

Table 3: Liste complète des 70 structures extraites de la bibliographie, avec formule (charge en exposant), groupe ponctuel, méthode de la géométrie de référence et statut de reconstruction (exacte ou relaxée GFN2-xTB).

Fichier (id)	Formule	G. ponctuel	Methode	Statut
N2	N2	Dinfh	CCSD(T)/aug-cc-pVTZ	exacte
N2+	N2 ⁺	Dinfh	B3LYP/aug-cc-pVDZ	exacte
N3+_linear	N3 ⁺	Dinfh	CCSD(T)/cc-pVTZ	exacte
N3+_triangle	N3 ⁺	D3h	CCSD(T)/cc-pVTZ	exacte
N3-_bent	N3 ⁻	C2v	B3LYP/aug-cc-pVDZ	exacte
N3-_linear	N3 ⁻	Dinfh	CCSD(T)/aug-cc-pVTZ	exacte
N3-_triangle	N3 ⁻	D3h	B3LYP/aug-cc-pVDZ	exacte
N3_radical	N3	Dinfh	B3LYP/aug-cc-pVDZ	exacte
N4+_rectangle	N4 ⁺	D2h	B3LYP/aug-cc-pVDZ	exacte
N4-_chain_planar	N4 ⁻	C2h	B3LYP/aug-cc-pVDZ	exacte
N4-_rectangle	N4 ⁻	D2h	B3LYP/aug-cc-pVDZ	exacte
N4_C2h_chain	N4	C2h	CCSD(T)/aug-cc-pVDZ	exacte
N4_D2d_puckered	N4	D2d	CCSD(T)/aug-cc-pVDZ	exacte
N4_D2h_rectangle_planar	N4	D2h	B3LYP/aug-cc-pVDZ	exacte
N4_Td	N4	Td	CCSD(T)/aug-cc-pVTZ	exacte
N4_C2v_butterfly	N4	C2v	CCSD(T)/aug-cc-pVDZ	GFN2-xTB
N5+_Vchain	N5 ⁺	C2v	CCSD(T)/6-311+G(2d)	exacte
N5-_bipyramid	N5 ⁻	D3h	B3LYP/aug-cc-pVDZ	exacte
N5-_pentagon	N5 ⁻	D5h	CCSD(T)/aug-cc-pVTZ	exacte
N6+_C2h_planar	N6 ⁺	C2h	B3LYP/aug-cc-pVDZ	exacte
N6+_C2v	N6 ⁺	C2v	B3LYP/aug-cc-pVDZ	exacte
N6-_Cs_chain	N6 ⁻	Cs	B3LYP/aug-cc-pVDZ	exacte

Table 3: Liste complète des 70 structures extraites de la bibliographie, avec formule (charge en exposant), groupe ponctuel, méthode de la géométrie de référence et statut de reconstruction (exacte ou relaxée GFN2-xTB).

Fichier (id)	Formule	G. ponctuel	Methode	Statut
N6_C2h_chain	N6	C2h	CCSD(T)/cc-pVDZ	exacte
N6_D3h_prism	N6	D3h	B3LYP/aug-cc-pVDZ	exacte
N6+_C2h_nonplanar	N6 ⁺	C2h	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N6-_C2_linked_triangles	N6 ⁻	C2	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N6_C2_book	N6	C2	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N6_D2_twisted	N6	D2	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N7+_chain	N7 ⁺	C2v	B3LYP/aug-cc-pVDZ	exacte
N7-_chain	N7 ⁻	C2v	B3LYP/aug-cc-pVDZ	exacte
N7_C2_linearZZ	N7	C2	B3LYP/aug-cc-pVDZ	exacte
N7_C2v_logcarrier	N7	C2v	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N7-Cs_ring_chain	N7	Cs	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N8-_C2h_ZEZ	N8 ⁻	C2h	B3LYP/aug-cc-pVDZ	exacte
N8-_C2h_chain	N8 ⁻	C2h	B3LYP/aug-cc-pVDZ	exacte
N8_C1_ZZE	N8	C1	B3LYP/aug-cc-pVDZ	exacte
N8_C2h_EEE	N8	C2h	B3LYP/aug-cc-pVDZ	exacte
N8_C2h_ZEZ	N8	C2h	B3LYP/aug-cc-pVDZ	exacte
N8_C2v_EZE	N8	C2v	B3LYP/aug-cc-pVDZ	exacte
N8_Oh_cubane_GS	N8	Oh	Becke3LYP/6-31G*	exacte
N8_Oh_cube	N8	Oh	B3LYP/aug-cc-pVDZ	exacte
N8_C2h_ladder	N8	C2h	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N8_C2v_branched	N8	C2v	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N8_C2v_ring	N8	C2v	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N8-Cs_ZEE	N8	Cs	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N8-Cs_azidopentazole	N8	Cs	Becke3LYP/6-31G* (topologie)	GFN2-xTB
N8-Cs_pentagonal	N8	Cs	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N8_D2d_octaazacyclooctatetrahedron	N8	D2d	Becke3LYP/6-31G* (topologie)	GFN2-xTB
N8_D2h_pentalene	N8	D2h	B3LYP/6-31G* (topologie exacte, geometrie relaxee GFN2-xTB)	GFN2-xTB
N8_D2h_ring_pendant	N8	D2h	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N9+_chain	N9 ⁺	C2v	B3LYP/aug-cc-pVDZ	exacte
N9-_chain	N9 ⁻	C2v	B3LYP/aug-cc-pVDZ	exacte
N9-_chain_twistedW	N9 ⁻	C2	B3LYP/aug-cc-pVDZ	exacte
N9_chain	N9	C2v	B3LYP/aug-cc-pVDZ	exacte
N9+_fused_rings	N9 ⁺	C2v	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB

Table 3: Liste complète des 70 structures extraites de la bibliographie, avec formule (charge en exposant), groupe ponctuel, méthode de la géométrie de référence et statut de reconstruction (exacte ou relaxée GFN2-xTB).

Fichier (id)	Formule	G. ponctuel	Methode	Statut
N9-_ring_chain	N9 ⁻	Cs	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N9_fused_rings	N9	C2v	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N10+_chain	N10 ⁺	C1	B3LYP/aug-cc-pVDZ	exacte
N10_D10h_ring	N10	D10h	Becke3LYP/6-31G*	exacte
N10_D2d_bispentazole_GS	N10	D2d	Becke3LYP/6-31G*	exacte
N10_D2d_linked5rings	N10	D2d	B3LYP/6-31G*	exacte
N10_D5h_prism	N10	D5h	B3LYP/aug-cc-pVDZ	exacte
N10+_rings	N10 ⁺	C1	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N10-_D2h_perp_rings	N10 ⁻	D2h	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N10_C3_cap	N10	C3	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N10_Cs_ring_chain	N10	Cs	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N10_cage_C2v	N10	C2v	B3LYP/aug-cc-pVDZ (topologie)	GFN2-xTB
N12_C2h_dipentazolyldiazene	N12	C2h	Becke3LYP/6-31G* (topologie)	GFN2-xTB
N20_Ih_dodecahedrane	N20	Ih	Becke3LYP/6-31G*	exacte
N5H_pentazole	N5H	C2v	MP2(fc)/6-31G*	exacte

5. Comparaison avec les structures identifiées par le pipeline de criblage

Les 70 géométries extraites de la bibliographie constituent une référence indépendante pour évaluer ce que le pipeline de criblage du dépôt (`polyN_pipeline.py`) retrouve par lui-même, sans aucune connaissance préalable de [GS] ni [B]. Deux campagnes de production déjà exécutées ont été utilisées comme “ensemble code” : `v2/resultats/production_2026-07-03/` (topologies générées par `geng/maygen`) et `resultats/seeds_pubchem/` (topologies amorcées à partir de squelettes carbonés PubChem convertis en N_x via `cxhx_to_nx.py`), soit 579 candidats optimisés GFN2-xTB au total.

5.1 Méthode

Pour chaque structure (biblio et code), un graphe de connectivité est construit à partir des coordonnées optimisées en reliant deux atomes N séparés de moins de 1,9 Å (même seuil que `build/render.py`, séparant sans ambiguïté liaisons N–N covalentes et contacts non-liants). Deux structures de même formule et même signe de charge sont considérées comme la **même topologie** si leurs graphes sont isomorphes (test exact `networkx.is_isomorphic`). Cette comparaison porte donc uniquement sur la **connectivité** : deux conformations E/Z d’une même chaîne, ou un cycle exactement plan et son analogue légèrement plissé, sont comptés comme une topologie identique (limites discutées à la fin de cette section).

Le fichier `N5H_pentazole` (seule structure biblio non purement azotée) est exclu de la comparaison, le pipeline ne traitant que des systèmes N_x . Par ailleurs, la configuration de production

ne calcule **que les espèces neutres à n pair et les ions (cation/anion) à n impair** (voir `v2/config_production.yaml` et `config_seeds.yaml`) : il n'existe donc structurellement aucun candidat "code" pour les radicaux neutres à n impair, ni pour les ions à n pair.

5.2 Groupes hors périmètre du pipeline actuel

21 des 69 structures comparées (30 %) tombent hors de ce périmètre par construction – il ne s'agit pas d'un échec de recherche mais d'une lacune de couverture du fichier de configuration :

- **Radicaux neutres à n impair** : N_3 (1), N_7 (3), N_9 (2) ;
- **Ions à n pair** : N_2^+ (1), N_4^- (2) / N_4^+ (1), N_6^- (2) / N_6^+ (3), N_8^- (2), N_{10}^- (1) / N_{10}^+ (2) ;
- **Hors gamme** : N_{20} neutre (1, au-delà de $n = 16$).

5.3 Résultats sur les 48 structures comparables

Formule / charge	Biblio	Retrouvées	Manquées	Topos. code en plus
N_2 neutre	1	1	0	0
N_3^-	3	3	0	0
N_3^+	2	2	0	0
N_4 neutre	5	3	2	2
N_5^-	2	1	1	6
N_5^+	1	1	0	5
N_6 neutre	4	4	0	8
N_7^-	1	1	0	18
N_7^+	1	1	0	6
N_8 neutre	15	13	2	17
N_9^-	3	0	3	24
N_9^+	2	1	1	15
N_{10} neutre	7	5	2	22
N_{12} neutre	1	0	1	15
Total	48	36 (75 %)	12	–

Table 4: Comparaison topologique entre les 48 structures biblio comparables et l'ensemble des candidats optimisés par `polyN_pipeline.py` (579 candidats, deux campagnes de production).

Structures biblio non retrouvées (topologiquement absentes de l'ensemble code) : N_4 (C2h_chain, C2v_butterfly), N_5^- (bipyramid), N_8 (C2v_branched, D2h_ring_pendant), N_9^- (les trois : chain, chain_twistedW, ring_chain), N_9^+ (fused_rings), N_{10} (bispentazole_GS, linked5rings), N_{12} (dipentazolyldiazene).

5.4 Synthèse qualitative

Le pipeline retrouve très bien les topologies canoniques peu contraintes diédralement – chaînes ioniques $N_3/N_7/N_9^+$, prisme et livre N_6 , cube/pentalène/azidopentazole N_8 – avec un taux de reconnaissance global de 75 % sur les 48 structures comparables, proche de 100 % dès que la topologie biblio est simple (chaîne, cycle, cage haute-symétrie). Les échecs se concentrent sur les topologies **bicycliques ou pontées à faible connectivité** (bispentazole N_{10} , dipentazolyldiazène N_{12} , l'ensemble des N_9^-) : soit le générateur de topologies (`geng` / squelettes PubChem) ne produit tout simplement pas ce graphe précis parmi les isomères testés, soit la reconstruction biblio de Niveau 2 elle-même s'avère fragile – c'est le cas frappant de N_{12} , dont

la relaxation GFN2-xTB (§2.2, même protocole que le pipeline) dissocie le pont diazène et fait s'écarter les deux cycles N_6 à 2,88 Å, questionnant la stabilité de ce composé à ce niveau de théorie indépendamment du code.

Deux limites méthodologiques doivent tempérer la lecture du tableau : (i) le test de connectivité est **aveugle aux stéréoisomères** – les cinq variantes E/Z de N_8 (ZZE, EEE, ZEZ, EZE, ZEE) et plusieurs isomères N_8 (cycle, cyclooctatétrène, pentalène) partagent un même graphe sous ce seuil : une structure “retrouvée” valide donc la connectivité, pas la conformation diédrale exacte ; (ii) pour N_4 , le seuil unique de 1,9 Å capture aussi le contact transannulaire faible du papillon C_{2v} plissé (1,58 Å dans la reconstruction GFN2-xTB), le rendant indiscernable du tétraèdre T_d – une frontière cage/cycle réelle mais que la méthode de graphe seule ne peut trancher.

Dans l'autre sens, le pipeline génère systématiquement beaucoup plus de topologies distinctes que les deux articles sources n'en documentent (jusqu'à 24 pour N_9^-), ce qui suggère un espace conformationnel largement sous-échantillonné par [GS] et [B] – un vivier de candidats N_9^-/N_{10} non rapportés dans la littérature, à confirmer par un niveau de théorie supérieur (DFT ou CCSD(T)) avant de les considérer comme physiquement pertinents.

6. Limites connues

- Les 25 structures “GFN2-xTB” du tableau reproduisent la **connectivité** décrite dans la référence mais pas nécessairement, au sens strict, la conformation diédrale exacte du minimum DFT/CCSD(T) publié (non documentée dans les figures sources).
- Quelques cycles annoncés *presque plans* présentent un très faible résidu de fermeture (jusqu'à $\sim 0,1$ Å pour le pentazole N_5H) attribuable aux arrondis à 1–2 décimales des angles publiés dans les figures sources.
- La longueur de liaison N–H du pentazole neutre (N_5H) n'étant pas indiquée dans [GS], une valeur standard de 1,00 Å a été utilisée.
- Les structures marquées GFN-FF (secours) dans `build/manifest.json` n'ont pas convergé en GFN2-xTB final ; leur géométrie provient du champ de force GFN-FF uniquement, légèrement moins précis que GFN2.

7. Reproductibilité

L'ensemble de la chaîne de production est scriptable et rejouable depuis `biblio_polyN/build/` :

```
python3 build/main.py           # regenere tous les .xyz + build/manifest.json
python3 build/render.py         # regenere les figures PNG
python3 build/make_table_tex.py # regenere table_structures.tex
pdflatex rapport_polyN_biblio.tex
```

La base de données des paramètres géométriques extraits des deux articles (longueurs de liaison, angles, groupe ponctuel, méthode, référence page par page) est entièrement lisible dans `build/molecules.py`.

8. Conclusion

Cette extraction fournit un jeu homogène de 70 structures polyazotées N_2 – N_{20} au format `.xyz`, directement exploitables dans VESTA pour la visualisation, ou comme géométries de


départ pour le pipeline `polyN_pipeline.py` de ce dépôt (optimisation GFN2-xTB, vérification de fréquences, enveloppes convexes de stabilité). Les structures marquées comme reconstruites exactement peuvent être considérées comme fidèles aux géométries publiées dans [GS] et [B] ; les autres constituent des modèles topologiquement corrects mais géométriquement approximatifs, faute d'information diédrale disponible dans les sources.

A. Représentations comparées biblio / code


Cette annexe illustre par le rendu boules-bâtonnets (même convention que la figure 1 : azote en sphères bleues, liaison tracée pour toute paire d'atomes N séparés de moins de 1,9 Å) une sélection de dix cas représentatifs de la comparaison topologique de la section 5, mélangeant topologies retrouvées par le pipeline et topologies manquées – auquel cas une ou deux alternatives réellement trouvées par le code pour la même formule/charge sont montrées à titre de comparaison (ce ne sont pas des reconstructions de la structure biblio, mais d'autres topologies présentes dans les runs de production).

A.1 Cas retrouvés

N3- (triangle)




code N3- (triangle)




Biblio N3-_triangle

N6 (D3h, prisme)




Code N3_anion_iso0002_conf2 (v2)

code N6 (prisme)




Biblio N6_D3h_prism

N8 (Oh, cubane)




Code N6_iso0004_conf1 (v2)

code N8 (cube)




Biblio N8_0h_cube

N7- (chaîne)



Code N8_neutral_iso0005_conf1 (seeds_pubchem)

code N7- (chaîne)





Dans les quatre cas, le graphe optimisé par le pipeline est isomorphe au graphe de la structure biblio (même nombre de liaisons, même séquence de degrés) : triangle N_3^- , prisme trigonal N_6 , cube N_8 et chaîne N_7^- sont retrouvés sans aucune information issue de [GS]/[B].

A.2 Cas manqués

N4 (C_{2v} , 'papillon')


code N4 (tetraedrique)



Biblio N4_ C_{2v} _butterfly

Code N4_iso0001_conf1 (v2)

code N4 (branche, alt.)




Code N4_neutral_iso0002_conf1 (seeds)


Figure 3: N_4 neutre : le papillon biblio (C_{2v}) contre les candidats du code pour cette formule.

Le papillon N_4 (C_{2v}) n'a pas d'équivalent topologique dans les candidats du code pour cette formule. Le premier candidat affiché correspond en fait au tétraèdre N_4 (T_d , autre structure biblio, déjà comptée comme retrouvée) ; le second est un arbre ramifié (degrés 1/2/2/3) distinct des deux topologies biblio.

N5- (bipyramide)




code N5- (pentagone)



Biblio N5-_bipyramid

Code N5_anion_iso0002_conf0 (v2)

code N5- (branche, alt.)



Code N5_anion_iso0005_conf2 (v2)

Figure 4: N_5^- : la bipyramide biblio contre les candidats du code pour cette formule/charge.

La bipyramide N_5^- (9 liaisons, sommets de degré 3–4) n'est pas retrouvée. Le premier candidat affiché correspond en fait au pentagone N_5^- (autre structure biblio, déjà comptée comme retrouvée) ; le second, topologie la plus stable trouvée par le code pour ce groupe, est une structure ramifiée à 5 liaisons nettement moins connectée que la bipyramide.






Figure 5: N_9^- : la chaîne biblio contre les candidats du code pour cette formule/charge.

Les trois isomères N_9^- de la biblio (dont la chaîne simple ci-dessus, 8 liaisons) sont absents des 24 topologies distinctes que le code trouve pour ce groupe – le plus proche en connectivité (troisième image, arbre ramifié à 9 liaisons) reste non isomorphe ; le premier candidat, cyclique à 11 liaisons, illustre l'autre extrême de l'espace exploré par le code.

N10 (D2d, bispentazole)



code N10 (alt.)




Biblio N10_D2d_bispentazole_GS Code N10_neutral_iso0057_conf0 (seeds_pubchem)


Figure 6: N_{10} neutre : le bispentazole biblio contre le meilleur candidat du code pour cette formule.

Le bispentazole N_{10} (14 liaisons) n'a pas d'équivalent : la topologie neutre N_{10} la plus stable trouvée par le code (11 liaisons) n'est pas isomorphe.

N12 (dissocie, 2x N6)



code N12 (alt., connexe)



Biblio N12_C2h_dipentazolyldiazene Code N12_iso0184_conf0 (v2)

Figure 7: N_{12} neutre : le dipentazolyldiazène biblio contre le meilleur candidat du code pour cette formule.

Point notable : le fichier .xyz biblio publié pour N_{12} est lui-même déconnecté sous le seuil de 1,9 Å (deux cycles N_6 séparés de 2,88 Å, visibles sur l'image) – il ne s'agit donc pas d'une dissociation survenue *après coup* dans un fichier intermédiaire distinct, mais de l'état final reporté dans xyz/. La topologie N_{12} neutre la plus stable trouvée par le code (13 liaisons, connexe) n'est de toute façon pas isomorphe à deux cycles séparés.

A.3 Aveuglement du critère de graphe aux stéréoisomères




Figure 8: Trois conformères E/Z de la chaîne N_8 , distincts dans [B] mais isomorphes sous le seuil de connectivité de 1,9 Å.

Ces trois isomères de conformation E/Z de la chaîne N_8 , géométriquement et expérimentalement distincts dans [B], partagent le même graphe de connectivité (chaîne à 7 liaisons) sous le seuil de 1,9 Å: la méthode de comparaison de la section 5 les compte comme une seule et même topologie “retrouvée” dès que le code identifie l’une d’entre elles, ce qui rappelle que l’accord porte sur la connectivité et non sur la conformation diédrale.

B. Comparaison à trois sources (biblio / **N_csp** / **polyN_study**)

Au-delà des structures extraites des deux articles de référence (section 5) et de celles retrouvées par `polyN_pipeline.py`, deux autres jeux de structures N_x neutres produits par des codes de génération antérieurs de ce dépôt ont été localisés dans d’autres répertoires `poly*` et importés dans `structures_externes/` :

- **N_csp** (408 structures, N_3 – N_{10}) : énergies initiales MACE, spécifie un groupe d’espace / fichier CIF par structure – vraisemblablement issu d’un code de prédiction de structure cristalline appliqué à des clusters isolés.
- **polyN_study** (50 structures, N_4 – N_{12}) : issues de `polynitrogen_minimahopping.py` (recherche

de minima par *minima hopping*, énergies MACE-OFF).

B.1 Protocole

Les 458 structures importées ont été relaxées ici avec le même niveau GFN2-xTB que le reste du dépôt, via le binding Python tblite (script `relax_imported_structures.py`, même routine `tblite_optimize` que `polyN_pipeline.py` – charge 0, multiplicité doublet si le nombre d’atomes est impair, sinon singulet), en local sur 9 processus parallèles (Apple M5, 10 cœurs). **312 / 458 structures (68%)** ont convergé en moins de 500 pas LBFGS (743 s au total) ; les échecs se répartissent en 89 erreurs d’évaluation SCF dès le point de départ et 57 non-convergences – notamment, 87 structures marquées “convergées” par le filtre MACE d’origine échouent en réalité sous GFN2-xTB, signe d’un désaccord notable entre les deux niveaux de théorie sur la stabilité de ces isomères.

Les structures biblio (section 5) avaient déjà été relaxées en GFN2-xTB via le binaire `xtb` en ligne de commande (même hamiltonien, implémentation différente de la même méthode). Les 337 structures convergées des trois sources sont groupées par (formule, charge) et classées par énergie GFN2-xTB croissante (eV/atome) ; tableau complet dans `biblio_polyN/comparison_table_3sources`.

B.2 Vainqueurs par groupe

Toutes les énergies ci-dessous sont post-vérification de fréquences (section C – vrais minima confirmés, spin correctement imposé).

B.2.1 a. Neutre

Sur les 7 groupes neutres où au moins une structure importée coexiste avec une structure biblio de même formule, la structure la plus stable (rang 1) provient d’un des codes de génération dans 6 cas sur 7 (tableau 5).

Formule	Origine du vainqueur	Topologie (vainqueur)	E (eV/at.)	Meilleure biblio (rang)	E biblio (eV/at.)
N ₄	polyN_study	chain	−78,4278	C2v_butterfly (10)	−78,278
N ₆	N_csp	ring-3-substituted	−78,8828	C2_book (16)	−78,708
N ₇	N_csp	chain	−78,8040	Cs_ring_chain (15)	−78,699
N ₈	biblio	C2v_ring	−79,0369	C2v_ring (1)	−79,036
N ₉	N_csp	ring-5-substituted	−78,8963	fused_rings (10)	−78,832
N ₁₀	N_csp	ring-5-substituted	−78,9383	cage_C2v (10)	−78,897
N ₁₂	polyN_study	ring-3-subst	−78,7110	C2h_dipentazolyldiazene (2)	−78,362

Table 5: Vainqueur (structure la plus stable) par groupe de formule neutre, toutes origines confondues (biblio, N_csp, polyN_study), comparé à la meilleure structure biblio du même groupe. Δ = écart entre la meilleure structure biblio et le vainqueur (positif = le vainqueur importé est plus stable). Rang de la structure biblio entre parenthèses (position dans le classement toutes origines confondues du groupe).

Pour N₈, le vainqueur est la structure biblio (C2v_ring) – aucune structure importée ne fait mieux dans ce groupe. Les deux sources importées (N_csp, polyN_study) ne contiennent que des clusters neutres : les tableaux b et c ci-dessous, bâtis uniquement à partir des structures biblio, n’offrent donc pas encore de comparaison à plusieurs origines pour les espèces chargées (cf. annexe D).

B.2.2 b. Cation

Formule	Structure (unique candidate biblio)	E (eV/at.)	Sauts freq.
N_6^+	N6+_C2h_nonplanar	-76,4957	0
N_9^+	N9+_fused_rings	-77,3283	2
N_{10}^+	N10+_rings	-77,4938	0

Table 6: Vainqueur par groupe de formule cationique. Une seule origine disponible (biblio) par groupe à ce stade – pas de comparaison multi-source possible tant que N_csp/polyN_study ne couvrent pas les espèces chargées.

B.2.3 c. Anion

Formule	Structure (unique candidate biblio)	E (eV/at.)	Sauts freq.
N_6^-	N6-_C2_linked_triangles	-79,0561	1
N_9^-	N9-_ring_chain	-79,6416	0
N_{10}^-	N10-_D2h_perp_rings	-79,7228	2


Table 7: Vainqueur par groupe de formule anionique. Même limite que le tableau 6 : une seule origine par groupe.

B.3 Représentations comparées (groupes neutres)


N4 -- chain (polyN_study)




N4 -- C2v papillon (biblio)




N6 -- ring-3-subst. (N_csp)



N6 -- C2 book (biblio)



N7 -- chain (N_csp)




N7 -- Cs ring-chain (biblio)




Figure 9: Vainqueurs neutres N_4 , N_6 , N_7 (colonne de gauche) contre la meilleure structure biblio du même groupe (colonne de droite).


N9 -- ring-5-subst. (N_csp)




N9 -- fused rings (biblio)




N10 -- ring-5-subst. (N_csp)



N10 -- C3 cap (biblio)



N12 -- ring-3-subst. (polyN_study)



N12 -- C2h dipentazolyldiazene (biblio)




Figure 10: Vainqueurs neutres N_9 , N_{10} , N_{12} (colonne de gauche) contre la meilleure structure biblio du même groupe (colonne de droite).

N8 -- C2v ring (biblio, gagnant)




Figure 11: N₈ : le vainqueur *est* la structure biblio (C2v_ring), seul groupe où aucune structure importée ne fait mieux.

Colonne de gauche : vainqueur (importé), sauf N₈ (biblio, seul et unique). Colonne de droite : meilleure structure biblio du même groupe, pour comparaison visuelle directe.

B.4 Synthèse

Sur les formules neutres où les trois sources se recoupent, les codes de génération de ce dépôt (pipeline d'énumération, CSP et minima hopping combinés) retrouvent systématiquement des isomères plus bas en énergie GFN2-xTB que les structures publiées dans les deux articles de référence – écarts de 40 à 350 meV/atome selon la formule, avec le plus grand écart sur N₁₂. Ceci ne remet pas en cause la pertinence des structures biblio (souvent choisies pour leur symétrie, leur intérêt spectroscopique ou leur accessibilité synthétique plutôt que pour être le minimum global GFN2-xTB), mais confirme que l'espace topologique exploré par énumération/CSP/minima-hopping est plus large que l'échantillon documenté dans la littérature pour ces tailles. Le cas N₈, seul groupe où la biblio reste devant, mériterait une recherche complémentaire côté code (le pipeline principal ne retrouve d'ailleurs pas cette topologie exacte, cf. section 5).

C. Vérification des fréquences (minima réels)

Une géométrie optimisée par GFN2-xTB a un gradient nul, mais un gradient nul n'implique pas un minimum local : une structure symétrique peut se trouver à un point-selle le long d'une distorsion brisant la symétrie (instabilité de type Jahn-Teller), invisible à l'optimisation de géométrie seule. Les 312 structures importées convergées (section B) ont donc été repassées par un calcul de Hessienne vibrationnelle (différences finies numériques, même niveau GFN2-xTB, `frequency_check.py`) : tout mode imaginaire significatif ($> 30 \text{ cm}^{-1}$, au-delà du bruit numérique sur les modes de translation/rotation) est suivi (petit déplacement le long du vecteur propre) puis la structure est réoptimisée, répété jusqu'à 5 fois si nécessaire.

C.1 Résultats

Calculs réussis	311 / 312
Minima vérifiés dès le premier calcul (0 saut)	272
Minima atteints après correction (1–3 sauts)	39
Points-selles non résolus (5 sauts épuisés)	0
Échec SCF (géométrie non évaluable)	1 (N_csp_N7_0015_bicyclic-5-5)

Table 8: Vérification de fréquences sur les 312 structures importées convergées (N_csp, polyN_study).

Les 39 corrections changent parfois significativement l'énergie – jusqu'à $-0,44$ eV/atome pour N_csp_N8_0032_bicyclic-3-5-6 (l'optimisation de gradient seule s'était arrêtée à un point-selle nettement au-dessus du vrai minimum voisin). Aucun point-selle n'est resté non résolu après 5 sauts, et le seul échec est un échec SCF dès le départ (structure déjà problématique lors de la relaxation initiale), pas une limite de la méthode de vérification elle-même.

C.2 Impact sur le classement de la section B

Les six vainqueurs importés du tableau comparatif (N₄, N₆, N₇, N₉, N₁₀, N₁₂) avaient tous 0 mode imaginaire dès le premier calcul (aucun saut nécessaire) : leur énergie et leur rang restent donc inchangés. Le classement de la section B est **confirmé** par cette vérification – les structures qui dépassent la meilleure structure biblio de leur groupe sont bien de vrais minima locaux, pas des artefacts d'une optimisation de gradient incomplète.

C.3 Extension aux 25 structures biblio

Les 25 structures extraites des articles (section 5) ont également été repassées par ce contrôle de Hessienne, en reprenant la charge et la multiplicité de spin exactement telles que déclarées dans biblio_polyN/build/molecules.py (pas devinées par une règle de parité) :

Calculs réussis	25 / 25
Minima vérifiés dès le premier calcul (0 saut)	19
Minima atteints après correction (1–2 sauts)	6
Points-selles non résolus	0

Table 9: Vérification de fréquences sur les 25 structures biblio, charge et multiplicité reprises de molecules.py.

C.3.1 Bug découvert et corrigé : multiplicité de spin ignorée par tblite

Un premier passage a produit un résultat suspect : N4_C2v_butterfly (triplet documenté, mult=3, seule structure du lot dont la multiplicité déclarée dévie de l'état par défaut/imposé par la parité électronique) convergeait après un saut vers une énergie quasi identique au singulet N₄ le plus stable du tableau de la section B. Vérification directe : sur une même géométrie, demander multiplicity=1 ou multiplicity=3 au constructeur TBLite(...) donne une énergie *identique*. Le binding tblite.ase.TBLite lit en réalité l'état de spin uniquement via atoms.get_initial_magnetic_moments().sum() – le mot-clé multiplicity= du constructeur est silencieusement ignoré (même classe de bug que celui déjà documenté pour charge=, corrigé dans le pipeline principal via set_initial_charges).

Portée réelle de l'impact, vérifiée cas par cas sur les 25 structures : seule N4_C2v_butterfly est concernée. Toutes les autres ont soit un nombre d'électrons pair avec singulet déclaré (état

par défaut, bug sans effet), soit un nombre d'électrons impair (molécule ou ion à charge impaire) où un doublet est physiquement imposé (aucun autre choix possible, bug sans effet non plus). Correctif appliqué dans `frequency_check.py` (`_apply_spin`, nouvelle fonction) et dans le `_tblite_optimize` de `polyN_pipeline.py` : les deux appellent désormais `atoms.set_initial_magnetic_moment` avant de créer le calculateur, symétriquement au mécanisme déjà en place pour la charge. Après correction, `N4_C2v_butterfly` converge dès le premier calcul (0 saut) vers $-78,2786$ eV/atome, quasi identique à sa valeur d'origine ($-78,2786$ eV/atome, calcul CLI `xtb` – correcte de bout en bout, indépendante de ce bug spécifique à `tblite`) : le triplet documenté dans l'article est bien confirmé comme un vrai minimum.

Ce bug étant localisé dans une routine partagée, il aurait pu affecter silencieusement tout calcul futur demandant un état de spin non par défaut (candidats du pipeline principal, familles chargées explorées avec une multiplicité non minimale) – corrigé avant que cela ne se produise ici, mais à garder en tête pour toute extension du criblage aux états de charge/spin des familles $N_x^{\pm}$.

C.4 Limite

Le classement de la section B ne porte que sur les formules neutres (seule charge commune aux trois sources) : les vainqueurs reportés y sont donc inchangés par cette extension aux structures chargées biblio. Une comparaison à trois sources sur les familles chargées resterait à construire une fois `N_csp/polyN_study` étendus aux ions.

D. Composés à étudier par nos codes

Le tableau 10 liste les couples (formule, charge) documentés dans la bibliographie (section 5) mais **non encore couverts** par les générateurs propres au dépôt (`polyN_pipeline.py`, `N_csp`, `polyN_study`) – soit parce que ces générateurs ne produisent à ce jour que des espèces neutres (`N_csp`, `polyN_study`), soit parce que la configuration de production du pipeline principal ne couvre pas cette parité formule/charge (section 5), soit parce qu'aucun générateur du dépôt n'atteint encore cette taille. Chaque ligne indique le nombre de structures biblio déjà disponibles comme référence pour une future comparaison, une fois le générateur étendu.

Formule	Charge	Struct. biblio	Remarque
N ₂	cation (+1)	1	hors périmètre parité (section 5)
N ₃	cation (+1)	2	hors périmètre parité
N ₃	anion (-1)	3	hors périmètre parité
N ₄	cation (+1)	1	aucun générateur du dépôt ne traite les ions chargés
N ₄	anion (-1)	2	idem
N ₅	cation (+1)	1	idem
N ₅	anion (-1)	2	idem
N ₆	cation (+1)	3	seule origine biblio dans le tableau 6
N ₆	anion (-1)	2	seule origine biblio dans le tableau 7
N ₇	cation (+1)	1	aucun générateur du dépôt ne traite les ions chargés
N ₇	anion (-1)	1	idem
N ₈	anion (-1)	2	idem (pas de cation N ₈ ⁺ documenté)
N ₉	cation (+1)	2	seule origine biblio dans le tableau 6
N ₉	anion (-1)	3	seule origine biblio dans le tableau 7
N ₁₀	cation (+1)	2	seule origine biblio dans le tableau 6
N ₁₀	anion (-1)	1	seule origine biblio dans le tableau 7
N ₂₀	neutre	1	au-delà de la taille maximale générée (N_csp : $n \leq 10$, polyN_study : $n \leq 12$)

Table 10: Couples (formule, charge) documentés dans la bibliographie mais non encore explorés par un générateur du dépôt – candidats prioritaires pour étendre la comparaison à trois sources (section B) aux espèces chargées et aux tailles $n > 12$.

Par ordre de priorité suggéré : (1) étendre N_csp/polyN_study (ou le pipeline principal) aux familles chargées des tailles déjà couvertes côté neutre (N₆[±], N₉[±], N₁₀[±]), qui disposent chacune de comparateurs biblio déjà vérifiés en fréquence (tableaux 6 et 7) – gain immédiat en comparabilité ; (2) couvrir les ions aux tailles intermédiaires actuellement hors périmètre du pipeline principal (N₂⁺, N₃[±], N₄[±], N₅[±], N₇[±], N₈⁻) ; (3) étendre la taille maximale générée au-delà de N₁₂ pour couvrir N₂₀ neutre.

E. Extension à une archive bibliographique complémentaire (38 articles)

Un second lot de 67 articles sur la chimie des composés polyazotés a été fourni (Archive.zip), indépendamment des deux articles [GS]/[B] traités aux sections précédentes. Cette annexe documente son traitement : catalogage, extraction des données géométriques, construction 3D, relaxation GFN2-xTB, vérification de fréquences et dédoublement contre le corpus complet (biblio + N_csp + polyN_study).

E.1 Catalogage et triage

Sur les 67 articles (titres/auteurs/espèces relevés dans biblio_polyN/archive_catalog.csv) : 2 sont des doublons du corpus déjà traité ([GS], [B]) et 3 autres sont des doublons internes à l'archive elle-même (même article sauvegardé deux fois sous des noms différents). Sur les 62 articles restants, 43 rapportent une géométrie exploitable ; après retrait des 5 doublons ci-dessus, **38 articles uniques** ont été effectivement traités.

E.2 Extraction des données

Les 38 articles ont été lus intégralement (texte, tableaux, et lecture directe des figures scannées ou des diagrammes annotés quand le texte seul était insuffisant). **174 espèces N-only** (formule + état de charge neutre/cation/anion) ont été identifiées et transcrites fidèlement – aucune valeur numérique n’a été inventée ou estimée : quand un article ne donnait qu’une description qualitative de la topologie sans paramètre géométrique chiffré, l’espèce a été cataloguée sans tentative de reconstruction.

Espèces N-only extraites	174
dont coordonnées cartésiennes complètes (<i>exact_coords</i>)	2
dont longueurs/angles de liaison (<i>bond_params</i>)	88
dont topologie seule, sans chiffre (<i>topology_only</i>)	83
dont états de transition / points-selles signalés par les auteurs	34
Étendue de taille couverte	N ₃ à N ₇₂
Répartition par charge	149 neutre, 14 cation, 11 anion

Table 11: Bilan de l’extraction sur les 38 articles de l’archive complémentaire.

Points notables rencontrés lors de cette lecture : une structure **expérimentale** du cation N₅⁺ obtenue par diffraction des rayons X sur monocristal (sel N₅⁺Sb₂F₁₁⁻) – rarissime dans ce domaine dominé par le calcul ; deux nouveaux états de charge (N₇⁺, N₇⁻) pour une formule jusqu’ici documentée uniquement neutre dans le corpus ; et plusieurs espèces explicitement signalées **instables par leurs propres auteurs** à un niveau de théorie supérieur à celui de leur découverte (par ex. deux isomères cage-like de type cyclooctatétraène et barrelène de N₈e.pdf, minima à HF/MP2 mais point-selles en DFT) – un rappel utile que la stabilité d’un isomère est toujours relative au niveau de théorie qui l’établit.

E.3 Construction, relaxation et vérification de fréquences

Sur les 174 espèces, **52 étaient directement exploitables** (données numériques suffisantes, taille ≤ 20 atomes, non signalées comme état de transition). Chacune a été reconstruite en 3D (coordonnées transcrites directement si disponibles ; sinon géométrie initiale bâtie à partir des paramètres de liaison via les fonctions de `biblio_polyN/build/geom.py`, ou par plongement direct du graphe de connectivité quand un tableau de liaisons complet était disponible), puis relaxée en GFN2-xTB et vérifiée en fréquence (même protocole que les sections C précédentes), avant dédoublement par isomorphisme de graphe contre le corpus complet (70 biblio + 408 N_csp + 50 polyN_study).

Doublons confirmés du corpus existant	31
Points-selles confirmés (non-minima GFN2-xTB)	9
Échec de construction (bicyclique 5+4 anneaux, non résolu)	1
Famille “cages à anneaux imbriqués” (N_nanotubes_06.pdf) – non fiable, voir texte	8
Structures nouvelles retenues	3
Total traité	52

Table 12: Bilan de la construction/relaxation/vérification sur les 52 espèces directement exploitables.

Anomalie identifiée et exclue : les 8 espèces de la famille “cages à anneaux imbriqués” de N_nanotubes_06.pdf (N₆ à N₂₀, groupes ponctuels D_{3h}/D_{4d}/D_{5h}/D_{6h}/O_h) ne donnent, dans

l'article, que des longueurs de liaison représentatives par symétrie – pas la connectivité complète ; leur construction est retombée sur le repli générique `generic_guess(shape="cage")`, qui s'avère **incapable de discriminer entre elles** : les 8 relaxations GFN2-xTB convergent vers une énergie quasi identique ($-71,016 \pm 0,0002$ eV/atome) quelle que soit la formule (N_6 à N_{20}) – signe que le repli générique produit un artefact non représentatif plutôt que la cage spécifique visée, l'algorithme de construction propre à l'article ("insertion d'anneaux en W imbriqués", section 2 de `N_nanotubes_06.pdf`) n'étant pas implémenté dans `geom.py`. Ces 8 espèces sont donc **exclues des résultats** et reportées en travail futur (tableau 10).

E.4 Les trois structures nouvelles

Espèce	Source	Méthode	E (eV/at.)	Conf.	Construction
N_{18} (C2v)	Gu <i>et al.</i> , J. Mol. Struct. (THEOCHEM) 428 (1998) 183	B3LYP/6-31G*	-78,6312	H	plongement direct du graphe (24 liaisons)
N_7^- (Cs, boat)	Liu, Zhao, Li, Theor. Chem. Acc. 107 (2002) 140	B3LYP/6-31G*	-79,7176	B	repli générique (ring7)
N_{11} (C2v, chaîne)	Thompson, Bledson, Strout, J. Phys. Chem. A (2002)	HF/cc-pVDZ	-78,8583	B	repli générique (chain)

Table 13: Les 3 espèces retenues comme nouvelles (absentes du corpus biblio+N_csp+polyN_study existant), avec niveau de confiance dans la fidélité de la reconstruction (H = haute, B = basse).




Figure 12: Les 3 nouvelles structures issues de l'archive complémentaire (géométrie GFN2-xTB relaxée, vérifiée en fréquence).

Seule $N_{18_C2v_cage}$ bénéficie d'une confiance **haute** : l'article donne un tableau complet des 24 liaisons indexées, ce qui a permis un plongement direct du graphe de connectivité (et non un repli générique) – c'est la seule des 3 dont on peut affirmer qu'elle représente fidèlement la topologie N_{18} (C2v) publiée. Les deux autres (N_7^- , N_{11}) reposent sur un repli générique faute de connectivité complète dans l'article source : leur énergie GFN2-xTB est physiquement raisonnable et elles constituent bien un minimum vérifié, mais **rien ne garantit qu'elles coïncident avec l'isomère précis décrit dans l'article** plutôt qu'un autre minimum de même formule/charge – à confirmer par une relecture ciblée de la figure originale avant tout usage nécessitant cette identification exacte.

E.5 Doublons à valeur ajoutée

Parmi les 31 doublons confirmés, un mérite mention spéciale : l'article de Christe *et al.* rapporte la structure **expérimentale** du cation N_5^+ (diffraction X sur le sel $N_5^+Sb_2F_{11}^-$) – topologiquement isomorphe à l'entrée `N5+_Vchain` déjà dans le corpus (calculée), mais issue d'une mesure directe plutôt que d'un calcul. Note de méthode : notre reconstruction utilise les longueurs/angles de liaison rapportés dans le texte comme point de départ d'une relaxation GFN2-xTB (le tableau des coordonnées cristallographiques complètes n'étant pas reproduit dans le corps de l'article), donc le fichier obtenu n'est pas une transcription littérale des coordonnées cristallines – mais la confirmation topologique par une source expérimentale indépendante reste une validation forte de cette famille de structures.

Les 34 espèces signalées comme états de transition ou points-selles par leurs propres auteurs (section précédente) et les 9 points-selles confirmés indépendamment par notre propre vérification de fréquences ne sont volontairement pas intégrées au corpus de minima – elles sont cataloguées dans `biblio_polyN/archive_extraction/` et `archive_new_structures_results.csv` pour une éventuelle discussion future sur les chemins de décomposition, mais n'apparaissent pas comme espèces stables dans ce rapport.

E.6 Travail reporté

Les 83 espèces *topology_only* (aucune donnée chiffrée dans l'article), les 16 grandes cages N_{24} – N_{72} (au-delà de la capacité actuelle de `geom.py`) et les 8 cages à anneaux imbriqués de `N_nanotubes_06.pdf` (section précédente) constituent un total de 107 espèces cataloguées mais non reconstruites – à traiter par une relecture ciblée des figures originales et/ou l'écriture d'un générateur de cage dédié, prochaine étape logique complétant le tableau 10.